Fama DIALLO

Data Scientist | Machine Learning & IA Générative

famadiallodf@gmail.com | 0669541243 | France (Mobile IDF) | linkedin.com/in/fama-diallo | github.com/Fama05-afk

Profil

Data Scientist diplômée d'un Master en Modélisation Statistique et Stochastique (Université de Bordeaux), spécialisée en Machine Learning, Deep Learning et Computer Vision. Expérience en modèles génératifs (GAN, Diffusion) pour la vision industrielle, mise en production de pipelines ML (MLflow, FastAPI, Docker) et intérêt marqué pour les LLMs et l'IA générative appliquée aux métiers.

Expériences

Stage de fin d'études – Computer Vision / Generative AI
*Tiama, Kestrel Vision, **1ère / 19 stagiaires*** *03/2025 – 08/2025*

- Génération synthétique d'images de défauts industriels rares pour pallier le déséquilibre de classes en environnement de contrôle qualité automatisé
- Implémentation et comparaison de deux approches génératives : GAN par détournement de l'inpainting et adaptation d'un modèle de diffusion au domaine industriel
- Pipeline d'optimisation complet (POC → stabilisation → tuning Optuna → fine-tuning) permettant un enrichissement du dataset de +58% ; suivi des expérimentations avec TensorBoard
- Résultats : PSNR +67%, FID –94%, MAE –98% ; validation par analyse des représentations latentes (t-SNE) et intégration au système de détection en production ; équipe Scrum, suivi Azure DevOps

Outils : Python (POO), PyTorch, GAN, Diffusion Models, Optuna, OpenCV, TensorBoard, t-SNE, Azure DevOps, Scrum

Stage en Analyse de Données
Ayor Water and Heating Solutions, Marsac *10/2023 – 01/2024*

- Analyse et préparation des données clients, ventes et commandes (séries temporelles, tendances) ; recueil des besoins métier
- Segmentation clients par clustering non supervisé (K-Means) et modélisation prédictive (régression logistique, Random Forest)
- Création et déploiement de tableaux de bord Power BI permettant le suivi opérationnel des KPIs et l'aide à la décision des équipes métier

Outils : Python, pandas, scikit-learn, SQL, Power BI , Excel, HubSpot CRM

Projets Data

Pipeline MLOps – Système de recommandation e-commerce
Projet personnel (Instacart) *03/2026*

- Pipeline de données : matrice sparse users × produits (32M transactions, 206k utilisateurs, 50k produits) avec pondération temporelle ; dashboard EDA interactif (KPIs, heatmaps, analyse temporelle) via Plotly
- Implémentation et comparaison de trois algorithmes : ALS et BPR (librairie `implicit`) et **EASE from scratch** (NumPy/SciPy) ; tuning Optuna ; **Hit Rate @10 : 13.3% → 16.2%** (+22%) avec ALS comme meilleur modèle ; tracking MLflow
- API REST FastAPI multi-modèles (ALS, BPR, EASE), interface Streamlit interactive (historique, recommandations, cohérence) ; conteneurisation Docker Compose

Outils : Python, NumPy, SciPy, implicit (ALS/BPR), Optuna, MLflow, FastAPI, Streamlit, Docker, Git

Détection d'éoliennes par imagerie satellite – Projet académique
Université de Bordeaux *10/2024 – 01/2025*

- Comparaison CNN from scratch (95.7% accuracy) vs transfer learning sur images satellites ; meilleure performance : ResNet50 fine-tuné à **98% accuracy** (MobileNetV2, EfficientNetB3, ResNet50)

Outils : Python, PyTorch, EfficientNet, ResNet50, MobileNetV2, OpenCV, scikit-learn, Git

Compétences techniques

ML & Deep Learning	PyTorch, scikit-learn, LightGBM, GAN, Diffusion Models, OpenCV
GenAI & NLP	Hugging Face, Transformers (BERT), RNN/LSTM/GRU
MLOps	MLflow, Optuna, FastAPI, Docker, Streamlit, Git, Azure DevOps
Data & Engineering	SQL, pandas, NumPy, SciPy, BigQuery, GCP, dbt
Visualisation	Power BI, Plotly, Matplotlib, R, TensorBoard

Formation

Master Modélisation Statistique et Stochastique – Université de Bordeaux *2023 – 2025*
Licence Mathématiques et Informatique – Université de Bordeaux *2019 – 2022*

Langues

Français : Bilingue natif | **Anglais :** B2 | **Wolof :** Langue maternelle